NoSQL adatbáziskezelők

A Redis kulcs-érték adattároló rendszer

Szathmáry László

Debreceni Egyetem Informatikai Kar

(utolsó módosítás: 2018. dec. 6.)

Redis

http://redis.io

A Redis egy nyílt forráskódú, kulcs-érték adattároló rendszer, ahol az adatok a memóriában helyezkednek el. A kulcs-érték adattároló rendszerek között a Redis a legnépszerűbb.

További jellemzők:

- 1. C-ben lett implementálva
- 2. az első változat 2009-ben jött ki
- 3. több platformra is létezik
- 4. nagyon sok programozási nyelvhez készült interfész (pl. C, C++, C#, Erlang, Go, Haskell, Java, Lua, Perl, PHP, Python, R, Ruby, Scala, stb.)
- 5. gyorsan megtanulható

Aktívan fejlesztik. BSD licenc alatt érhető el.

Leegyszerűsítve, a Redis egy hash szótár, ahol a kulcsokhoz értéket lehet rendelni. Viszont, és itt tér el más hasonló adattárolóktól, a Redis esetében az érték nem csak sztring lehet!

Az érték lehet:

- sztring
- lista
- halmaz
- rendezett halmaz (az elemek rendezve lesznek egy score érték alapján)
- hash

A szerver oldalon magas szintű műveletek is elvégezhetők, pl. lista rendezése, halmazműveletek (unió, metszet, különbség), stb.

Perzisztencia

A Redis a teljes adathalmazt a memóriában kezeli. Viszont:

- 1. Kilépéskor lemezre lehet menteni az adatbázis tartalmát.
- Indításkor a lementett adatbázist be lehet tölteni.

Továbbá a rendszer bizonyos időközönként automatikusan mentéseket végez (snapshotting). Ez lehet teljes vagy inkrementális.

Teljesítmény

C-ben lett implementálva (nagyon gyors); a memóriában dolgozik (kevés az I/O művelet, lásd fent).

Egyetlen processzben fut, ill. egyetlen szálat használ (single threaded) => a műveletek atomi műveletek.

Tranzakció

Minden művelet atomi. Ha több műveletet szeretnénk egy atomi csoportba összefogni, akkor a tranzakciók segítségével ez megoldható.

Telepítés forrásból

http://redis.io/download

```
# keressük meg a legfrissebb verziót
$ wget http://download.redis.io/releases/redis-2.8.19.tar.gz
$ tar xvzf redis-2.8.19.tar.gz
$ cd redis-2.8.19
$ make
$ make
$ make test
# opcionális, Ubuntu alatt a /usr/local/bin -be telepíti:
$ sudo make install
```

Telepítés csomagkezelővel #1

Telepítés **Ubuntu** Linux rendszeren

```
$ sudo apt install redis
```

A "redis-server" csomag tartalmazza a szervert, míg a parancssoros kliens a "redistools" csomagban található. A fenti parancs hatására mindkettő feltelepül.

Telepítés csomagkezelővel #2

Telepítés **Manjaro** Linux rendszeren:

\$ sudo pacman -S redis

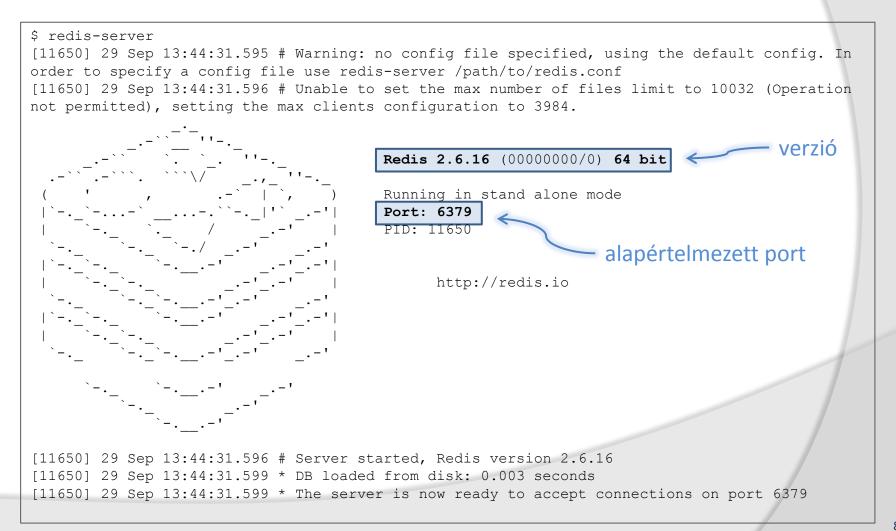
A Manjaro egy Arch Linuxra épülő disztribúció, mely az utóbbi időben egyre nagyobb népszerűségre tett szert. Jól összeállított rendszer, mely az Ubuntu-hoz hasonlóan könnyen telepíthető, könnyen használható.

A Manjaro repository-kba nagyon gyorsan bekerülnek az új verziók, így itt valószínűleg nem szükséges a forrásból való telepítés.

Itt csak egyetlen csomagot szükséges telepíteni, mely mind a szervert, mind pedig a parancssoros klienst tartalmazza.

Manuális indítás

A szervert manuálisan a redis-server parancs kiadásával tudjuk elindítani:



Automatikus indítás #1

Ubuntu rendszeren

Ubuntu esetén a telepítő beregisztrálja, hogy a redis szerver bootolás után automatikusan elinduljon. Forrásból való telepítés esetén az itt leírtak szerint járjunk el:

https://www.digitalocean.com/community/articles/how-to-install-and-use-redis

Arról, hogy fut-e a szerver, a legegyszerűbben így tudunk meggyőződni:

```
$ redis-cli
127.0.0.1:6379>
```

Ha a kliens indításakor nem kapunk hibaüzenetet, akkor fut a szerver.

Automatikus indítás #2

Manjaro rendszeren

Manjaro Linuxon a bootolás utáni automatikus indítást engedélyezni kell:

```
$ systemctl enable redis.service
```

Ha nem akarjuk újraindítani a rendszert, akkor a köv. paranccsal tudjuk elindítani a redis szolgáltatást:

```
$ systemctl start redis.service
```

Itt is a "redis-cli" paranccsal tudjuk a legegyszerűbben leellenőrizni, hogy fut-e a szerver:

```
$ redis-cli
127.0.0.1:6379>
```

Adatszerkezetek

A Redis **öt** különböző adatszerkezetet használ. Ebből csak egy tekinthető tipikusan kulcs-érték struktúrának.

Kulcs: tetszőleges sztring, pl.: users: jabba

A kettőspontnak nincs speciális jelentése, elhatárolónak szokták használni.

Érték: a kulcshoz rendelt érték

A legtöbb esetben a Redis ezt egy byte-sorozatnak veszi s nem foglalkozik vele, hogy mi van benne.

```
$ redis-cli
redis 127.0.0.1:6379> set users:jabba "Jabba Laci"
OK
redis 127.0.0.1:6379> get users
(nil)
redis 127.0.0.1:6379> get users:jabba
"Jabba Laci"
redis 127.0.0.1:6379>
```

parancssoros kliens

Adatszerkezetek

"A kulcs minden, az érték semmi."

Azaz, a Redis-ben az értékekre nem lehet lekérdezéseket írni. Pl. egy JSON érték a Redis számára csupán egy közönséges sztring.

A Redis nagyszerűen használható bizonyos feladatokra, de nem nyújt általános megoldást mindenre. Nem arra lett kitalálva, hogy RDBMS rendszereket váltson le.

A Redis-ben minden parancs egy bizonyos adatszerkezetre vonatkozik. A parancsok teljes listája itt tekinthető meg: http://redis.io/commands.

- 1. sztring
- 2. hash
- 3. lista
- 4. halmaz
- 5. rendezett halmaz

példák később

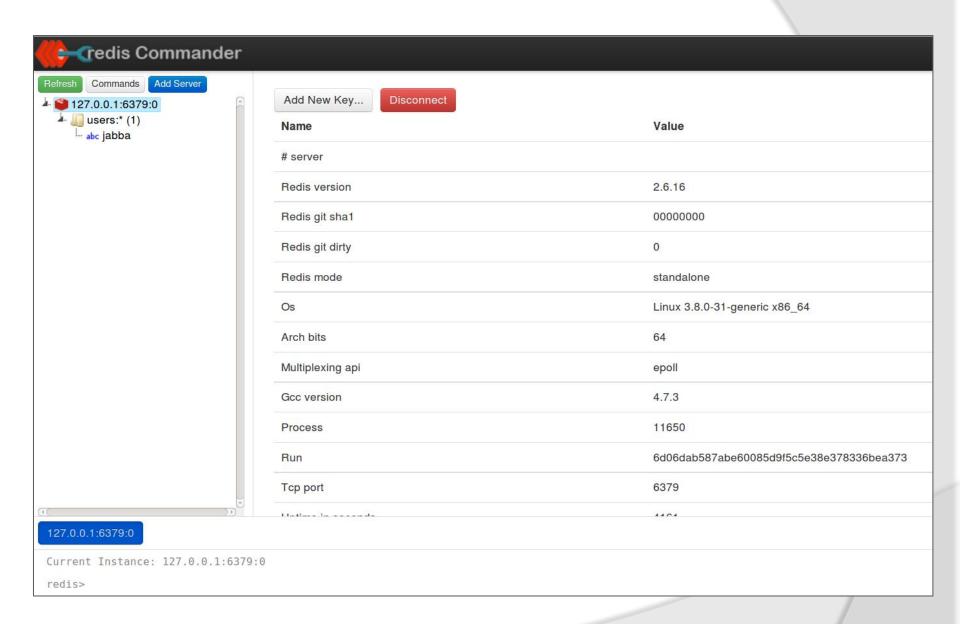
Webes adminisztrációs felület

A *Redis Commander* egy node.js-ben írt webes adminisztrációs felület a Redis-hez. Szerepét tekintve a PHPMyAdmin-hoz lehetne hasonlítani.

http://nearinfinity.github.io/redis-commander/

Telepítése

```
$ sudo npm install -g redis-commander
$ redis-commander
path.existsSync is now called `fs.existsSync`.
listening on 8081
Redis Connection 127.0.0.1:6379 Using Redis DB #0
```



A Redis Commander webes felülete (localhost:8081)

GUI adminisztrációs felület

Egy másik adminisztrációs felület a Redis Desktop Manager, mely egy C++ - ban írt natív alkalmazás.

Telepítése

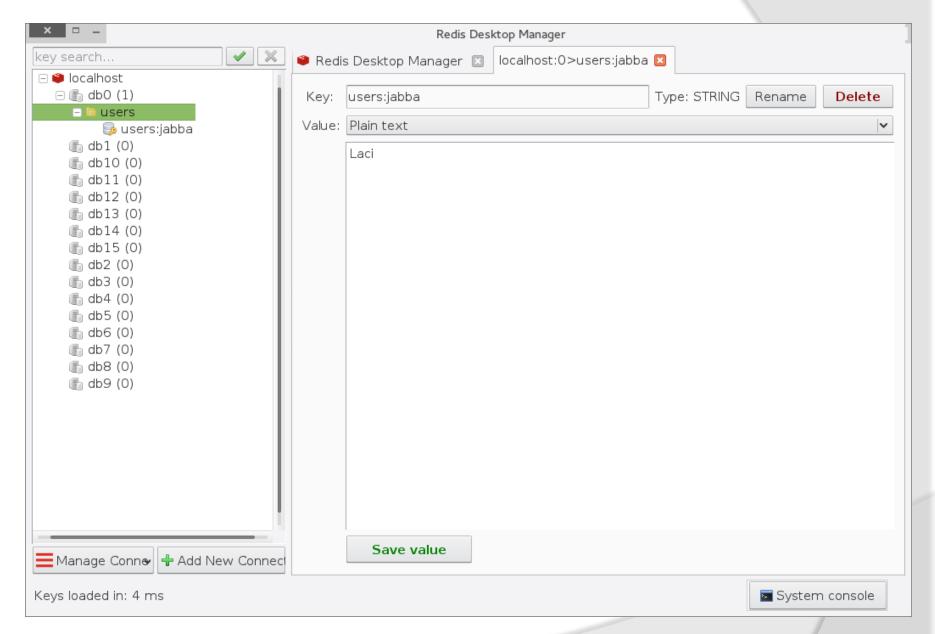
http://redisdesktop.com/

\$ sudo snap install redis-desktop-manager

Indítása:

\$ redis-desktop-manager.rdm

Ehhez az kell, hogy a /snap/bin mappa benne legyen a PATH-ban.



A Redis Desktop Manager felülete

A Redis használata alkalmazásokból

A Redis-t számos programozási nyelvből tudjuk használni. Nézzünk meg néhány példát a Python programozási nyelv segítségével.

Először is telepítsük fel a redis csomagot:

```
sudo pip3 install redis -U
```

Ellenőrizzük le, hogy sikeres volt-e a telepítés:

```
[08:34:09] ~ $ python3
Python 3.5.2 (default, Nov 23 2017, 16:37:01)
[GCC 5.4.0 20160609] on linux
Type "help", "copyright", "credits" or "license" for more information.
>>> import redis
>>> ■
```

Rendben, az importálás nem jelzett hibát.

Kapcsolódás a szerverhez

```
#!/usr/bin/env python
 2
   import sys
    import redis
 5
    r = redis.Redis("localhost", 6379)
    #r = redis.Redis() # use default values
8
9
    def check server():
10
        try:
11
            r.info()
12
        except redis.exceptions.ConnectionError:
13
            print >>sys.stderr, "Error: cannot connect to redis server. Is the server running?"
14
            sys.exit(1)
15
16
17
    def main():
18
        check server()
19
        print "The server is up and running."
20
21
    #######################
22
23
   if name
                == " main ":
24
        main()
```

Példák #1

```
>>> import redis
>>> r = redis.Redis() # default: localhost, port 6379
>>> r.set("name", "jabba")
True
>>> r.get("name")
'jabba'
# the list is called "test"
# rpush: right push, i.e. put an element on its right side (tail)
>>> r.rpush("test", 24)
1L
>>> r.rpush("test", 67)
2L
>>> r.rpush("test", 9)
# list all the elements (-1 is the index of the last element)
>>> r.lrange("test", 0, -1)
['24', '67', '9']
# number of elements
>>> r.llen("test")
# delete the list if you don't need it anymore
>>> r.delete("test")
```

Példák #2

```
>>> import redis
>>> r = redis.Redis()  # default: localhost, port 6379
>>> r.incr("goku:powerlevel")
1
>>> r.incr("goku:powerlevel")
2
```

Gyakori művelet valamilyen számláló tárolása Redis-ben. Mivel minden művelet atomi, illetve a Redis egyetlen szálat használ, ezért egy Redis adattárolót több processz is használhat konkurrens módon.

Egy termelő-fogyasztó alkalmazás Redis-szel például triviálisan megoldható.

Példák #3

```
>>> import redis
>>> r = redis.Redis()
>>> r.set("name", "jabba")
                                              automatikusan törlődjön a
True
                                              kulcs-érték pár 10 mp. múlva
>>> r.get("name")
'jabba'
>>> r.expire("name", 10)
True
>>> r.ttl("name")
6L
>>> r.ttl("name")
                                             ttl: time to live
4L
>>> r.ttl("name")
>>> r.get("name")
```

Unix időbélyeg is használható, pl. r.expireat ("name", 1356933600)

A Redis ideális választás lehet adatok cache-elésére.

Autentikáció #1

Ha a Redis-t az otthoni gépünkön használjuk, akkor nincs szükség azonosításra. Ha viszont egy szerverre telepítjük fel, akkor már le kell védeni az illetéktelenek elől.

A jelszavas védelemhez a következő sort kell betenni a /etc/redis.conf állományba:

requirepass "secret password"

Mivel a Redis másodpercenként rengeteg kérést ki tud szolgálni, ezért a Redis szerzője szerint mindenképpen hosszú, nehezen kitalálható jelszót válasszunk. Ellenkező esetben egy egyszerű brute force támadással is hozzá tudnak férni a jelszóhoz.

Autentikáció #2

Azonosítás parancssorból:

```
$ redis-cli
127.0.0.1:6379> info
NOAUTH Authentication required.
127.0.0.1:6379> auth "secret password"
OK
127.0.0.1:6379> info
# Server
redis_version:2.8.4
redis_git_sha1:00000000
...
```

azonosítás után már használható

Autentikáció #3

Azonosítás Python alkalmazásban:

```
>>> import redis
>>> r = redis.Redis()
>>> r.info()
Traceback (most recent call last):
  File "<input>", line 1, in <module>
  File "/usr/local/lib/python2.7/dist-packages/redis/clie
    return self.execute command('INFO')
  File "/usr/local/lib/python2.7/dist-packages/redis/clie
    return self.parse response(connection, command name,
  File "/usr/local/lib/python2.7/dist-packages/redis/clie
    response = connection.read response()
  File "/usr/local/lib/python2.7/dist-packages/redis/cong
    raise response
ResponseError: NOAUTH Authentication required.
>>> r = redis.Redis(password="secret password")
>>> len(r.info())
67
>>>
```

Linkek

Redis HQ http://redis.io

Redis parancsok

http://redis.io/commands

Karl Seguin: The Little Redis Book

http://openmymind.net/2012/1/23/The-Little-Redis-Book/

Getting Started: Redis and Python

http://degizmo.com/2010/03/22/getting-started-redis-and-python/

Redis Python client: redis-py

https://github.com/andymccurdy/redis-py

Python wrapper for Redis datatypes

https://github.com/Doist/redis_wrap

Alternatívák

Az alternatívák közül a legismertebb a Memcached.

A Memcached egy nagy méretű hash táblázatot biztosít, melyben kulcs / érték párokat tudunk tárolni. Általában dinamikus weboldalak használják adatok és objektumok tárolására, lecsökkentve ezzel az adatbázisból való olvasások számát.

Példa:

```
function get_foo(foo_id)
    foo = memcached_get("foo:" . foo_id)
    return foo if defined foo

    foo = fetch_foo_from_database(foo_id)
    memcached_set("foo:" . foo_id, foo)
    return foo
end
```

Előbb a cache-ből próbáljuk kiolvasni az elemet. Ha nincs benne, akkor kiolvassuk az adatbázisból, majd betesszük a cache-be. A 2. hívás esetén már a cache-ből tudjuk kiolvasni az elemet.

A Redis használata cache-ként

Ha a Redis-t cache-ként akarjuk használni, két lehetőségünk is van.

- A betett elemeknek beállítunk egy élettartamot (expire), így azok egy bizonyos idő múlva törlődnek. Így elejét vehetjük annak, hogy a memória szép lassan beteljen.
- 2) Direkt cache módban használjuk a Redis-t. Ekkor beállíthatjuk, hogy maximum mennyi memóriát használhat. Ha elértük ezt a limitet, akkor a legrégebben használt elemet törli, s így be tudja tenni az új elemet. Vagyis a cache tartalma folyamatosan változik, a régi elemek törlődnek, helyet adva az újaknak. Ehhez a következőt kell beírni a /etc/redis.conf állományba:

maxmemory 2mb
maxmemory-policy allkeys-lru

2 MB-os memórialimit használata. A Redis ekkor a Memcached-hez hasonlóan működik.

RQ -- Redis Queue

http://python-rq.org/



Mivel a Redis-ben minden művelet atomi, illetve egyetlen szálat használ, ezért a termelő - fogyasztó alkalmazásokban nagyszerűen alkalmazható **sorként** is.

A Redis Queue (röviden RQ), mely egy ún. *job queue* rendszer, ezt a feladatot valósítja meg. Vagyis lehetővé teszi *job*-ok sorba való felfűzését, majd ezen job-ok háttérben való feldolgozását *worker* processzek segítségével.

A job-ok tárolására a Redis-t használja. Előnye a rendkívül egyszerű telepítés és egyszerű használat.

Job: tetszőleges Python függvény, melyet a worker processz(ek) aszinkron módon hív(nak) meg. Mivel a job-ok szerializációjára a Python pickle formátumát használja, ezért az RQ csak Python környezetben használható.

Alternatív job queue rendszerek: <u>Celery</u>, <u>Resque</u>, <u>Huey</u>, stb.

Áttekintés: queues.io.

Az RQ telepítése

Telepítés

```
$ sudo pip install rq
```

RQ dashboard

Az "rq-dashboard" telepítése opcionális. Ez egy webes felülettel rendelkező monitorozó alkalmazás, mellyel az RQ futását lehet követni.

```
$ sudo pip install rq-dashboard
```

Az "rq-dashboard" paranccsal tudjuk elindítani, majd a http://0.0.0.0:9181/címen lehet elérni.

Nézzük meg az RQ használatát egy konkrét példán keresztül.

Az alábbi címen 38 157 db háttérkép található:

https://gist.github.com/jabbalaci/10009101

Egy-egy bejegyzés csupán a file nevét tartalmazza, pl. 95yWLrG.jpg. Átalakítás teljes URL-lé:

```
95yWLrG.jpg => http://i.imgur.com/95yWLrG.jpg
```

Töltsük le a képeket egy adott könyvtárba (pl. /trash/wallpapers). A letöltésen kívül még felbontás alapján is válogassuk szét a képeket. Ha pl. egy kép 1024x768-as méretű, akkor a kép a

/trash/wallpapers/1024x768 nevű könyvtárba kerüljön.

processor.py

```
8 import os
9 from unipath import Path
10 from PIL import Image
11 import shutil
12
  BASE DIR = "/trash/wallpapers"
15
16
17 def download(url):
18
       fname = Path(url).name
19
       fullname = "{folder}/{fname}".format(folder=BASE_DIR, fname=fname)
       cmd = 'wget --quiet {url} -0 {fullname}'.format(url=url, fullname=fullname)
20
21
       os.system(cmd)
22
       img = Image.open(fullname)
23
       width, height = img.size
24
       to_dir = "{base}/{w}x{h}".format(base=BASE_DIR, w=width, h=height)
25
       Path(to_dir).mkdir()
       shutil.move(fullname, to_dir)
26
```

main.py

```
4 from redis import Redis
5!from rq import Queue
7 from processor import download
9 g = Queue(connection=Redis())
12 def main():
      with open("list.txt") as f:
           for line in f:
               line = line.rstrip("\n")
16
               url = "http://i.imgur.com/{img}".format(img=line)
               q.enqueue(download, url)
```

Magyarázat

Egy külön modulba (jelen esetben a processor.py fájlba) kitesszük azt a függvényt, aminek a végrehajtása több időt vesz igénybe, s emiatt a háttérben, aszinkron módon szeretnénk majd végrehajtani. A download függvény megkapja egy kép URL-jét. Ezt letölti egy adott könyvtárba, majd megnézi a kép dimenzióját (szélesség, magasság). A dimenziónak megfelelő könyvtárat létrehozza, s ide áthelyezi a képet.

A main.py fájlban létrehozunk egy Redis sort. A képek listáját tartalmazó fájlt bejárjuk; minden egyes bejegyzést átalakítunk rendes URL-lé, majd a sorba betesszük a download függvényt az URL paraméterrel együtt.

Worker processz(ek) indítása

Már csak a worker processzt kell elindítani. Ehhez lépjünk be a projekt könyvtárába (ahol a processor.py található), majd adjuk ki az "rqworker" parancsot. Akár több rqworker-t is indíthatunk a gyorsabb feldolgozás érdekében.

Queues

This list below contains all the registered queues with the number of jobs currently in the queue. Select a queue from above to view all jobs currently pending on the queue.

Queue	Jobs
□ default	36730
	0

Workers

This list below contains all the registered workers.

State	Worker	Queues
•	vostro.7822	default
•	vostro.7757	default
•	vostro.7857	default
•	vostro.7787	default

Jobs on default

This list below contains all the registered jobs on queue default, sorted by age (oldest on top).

Name

Age

Actions

12 hours ago

Actions

Az rq-dashboard webes felülete (localhost:9181).

Bal oldalt: feldolgozandó job-ok száma. Jobb oldalt: jelenleg 4 worker processz fut.

http://www.celeryproject.org/

Celery



Az RQ "nagytestvére" a Celery, mely Python környezetben a legismertebb, legelterjedtebben használt *task queue / job queue* rendszer. A job-ok sorban való feldolgozásán kívül támogatja a crontab-szerű időzített / ismételt feladatvégrehajtást is.

Első lépésben meg kell adnunk egy üzenetküldő rendszert (*message broker*), ami a job-ok sorban való tárolására fog szolgálni. A Celery számos ilyen rendszert támogat:

- <u>RabbitMQ</u> (Erlang-ban implementált, stabil, éles környezetre ajánlott broker)
- Redis (egyszerűen telepíthető, gyors, de éles környezetben talán kevésbé megbízható mint az előző)
- adatbázis (nem erre lett kitalálva, nem ajánlott)

A továbbiakban az egyszerűség kedvéért a Redis-t fogjuk használni.

Celery

A Celery az eredmények tárolására egy másik rendszert használ (bár ez megegyezhet az előzővel). A következők közül választhatunk:

- memcached
- Redis
- RabbitMQ
- MongoDB
- stb.

Az egyszerűség kedvéért ismét a Redis-t fogjuk felhasználni erre a célra.

Telepítés

\$ sudo pip install celery

Flower

A Celery-hez is létezik egy webes felülettel rendelkező monitorozó alkalmazás, mellyel a Celery futását lehet követni. Ehhez a <u>flower</u> csomagot kell telepíteni (sudo pip install flower), majd a flower paranccsal tudjuk elindítani.

Nézzük meg a Celery használatát egy konkrét példán keresztül. A feladat legyen ugyanaz, mint az RQ esetében, azaz töltsük le a https://gist.github.com/jabbalaci/10009101 címen található képeket s felbontás szerint válogassuk szét őket külön könyvtárakba.

```
config.py
    from celery import Celery
    celery = Celery(include=['processor'])
    celery.conf.update(
6
        BROKER URL='redis://localhost',
        CELERY RESULT BACKEND='redis://localhost',
8
9
        CELERY TASK SERIALIZER='json',
10
        CELERY RESULT SERIALIZER='json',
11
        CELERY ACCEPT CONTENT=['json'],
12
13
        CELERY TASK RESULT EXPIRES=60,
14
15
        CELERY TIMEZONE='Europe/Budapest',
        CELERY ENABLE UTC=True,
16
17
```

A projekt konfigurációs részét érdemes kitenni egy külön modulba (config.py állomány). Itt létrehozunk egy celery nevű objektumot, s a későbbiekben ezen keresztül tudjuk majd elérni a Celery rendszert.

A celery objektum konstruktorában egy listában fel kell tüntetni azokat a modulokat, melyek a háttérben végrehajtandó függvényeket tartalmazzák.

A továbbiakban beregisztráljuk, hogy mind az üzenetek küldésére, mind az eredmények tárolására a Redis-t akarjuk használni. A könnyebb olvashatóság kedvéért mindent JSON formátumban teszünk be a Redis-be.

A végén jelezzük, hogy a Redis-ben az eredmények 60 másodperc múlva automatikusan törlődjenek. Ezzel elejét vehetjük annak, hogy a Redis szép lassan megtöltse a memóriát.

processor.py

```
import os
    import shutil
                                                           celery objektum behozása
    from PIL import Image
    from unipath import Path
 8
    from config import celery
                                                           jelezzük, hogy a függvényt
10
                                                           egy háttérben végrehajtandó
11
    BASE DIR = "/trash/wallpapers"
12
                                                           taszknak szánjuk
13
14
    @celery.task
15
    def download(url):
16
        fname = Path(url).name
        fullname = "{folder}/{fname}".format(folder=BASE DIR, fname=fname)
17
        cmd = 'wget --quiet {url} -0 {fullname}'.format(url=url, fullname=fullname)
18
19
        os.system(cmd)
20
        img = Image.open(fullname)
21
        width, height = img.size
        to_dir = \frac{\text{base}}{\{w\}x\{h\}} . format(base=BASE DIR, w=width, h=height)
22
23
        Path(to dir).mkdir()
        shutil.move(fullname, to dir)
24
```

main.py

```
from processor import download

def main():
    with open("list.txt") as f:
        for line in f:
            line = line.rstrip("\n")
            url = "http://i.imgur.com/{img}".format(img=line)
            download.delay(url)
```

A download függvényt nem közvetlenül hívjuk meg. A delay hívással jelezzük, hogy ezt a függvényt aszinkron módon akarjuk meghívni, amiről majd a Celery fog gondoskodni.

Worker processz(ek) indítása

Már csak a worker processzt kell elindítani. Ehhez lépjünk be a projekt könyvtárába (ahol a config.py található), majd adjuk ki az alábbi parancsot:

```
$ celery -A config worker -l info
```

-A config: a celery objektum a config.py állományban van definiálva

worker: task queue indítása – l info: naplózás beállítása

Nagy előnye a Celery-nek, hogy egyszerre több szálon is indíthatunk worker processzeket. Például így indíthatunk egyszerre 4 worker processzt:

```
$ celery -A config worker -c 4 -l info
```

A Flower indítása (maradva az előző példánál):

\$ flower -A config

innen tudja majd, hogy az eredmények a Redis-ben jelennek meg

Celery Flower



Workers



	Name	Status	Concurrency	Completed Tasks	Running Tasks	Queues
	celery@jabba-nancy	Online	4	1803	4	celery

Broker: redis://localhost:6379//

A Flower webes felülete (localhost:5555). Mint látható, jelenleg 4 worker processz fut.