python

Szkriptnyelvek

Szathmáry László
Debreceni Egyetem
Informatikai Kar

10. Gyakorlat

- weboldalak letöltése
- JSON szerializáció

(utolsó módosítás: 2026. jan. 16.)

2025-2026, 2. félév

Weboldalak letöltése

```
4  import urllib.request
5
6  def main():
7      response = urllib.request.urlopen("http://python.org")
8      raw = response.read()
9      print(type(raw))    # bytes
10     # print(raw)
11
12     html = raw.decode("utf-8")
13     print(type(html))    # str
14     # print(html)
```

Mivel ez gyakori művelet, ezért ezt gyorsan tegyük is bele a `pygyak.py` modulunkba `get_page()` néven. Használata a következőképpen nézzen ki:

```
3  from pygyak import get_page
4
5  url = 'http://python.org'
6
7  def main():
8      print(get_page(url))
```

Sztringet adjon vissza!

URL letöltése (ez lehet HTML, kép, stb.).
A letöltött objektum a fájlrendszerben jelenik meg:

```
4 import urllib.request
5
6 url = "http://www.nhdfl.org/uploads/NHB%20photos/HBOP2.jpg"
7
8 def main():
9     urllib.request.urlretrieve(url, "/tmp/forest.jpg")
```

Vagy használhatunk a letöltésre egy külső programot is, pl. a `wget` -et:

```
3  import os
4
5  url = 'http://wallpapers.leovacity.be/images/Forrest_wallpaper.jpg'
6  to = '/tmp/forrest.jpg'
7
8  def main():
9      cmd = 'wget {url} -O {output}'.format(url=url, output=to)
10     print(cmd)
11     os.system(cmd)
```

külső program hívása külön processzben

A **requests** modul

A Python standard library a következő modulokat tartalmazza URL-ek letöltésére:
- urllib (https://docs.python.org/3/library/urllib.html), gyűjtő-modul
- urllib.request (https://docs.python.org/3/library/urllib.request.html)
- ...

Viszont ezeknek a használata eléggé körülményes tud lenni :(

Ezért érdemes megismerkedni a **requests** modullal (link). Ez nem része a standard library-nek, külön kell installálni. Sokkal egyszerűbb a standard könyvtár moduljainál…

Az előző link alján részletes User Guide található.
Előadás a modul szerzőjétől.

Ezt csak 1x kell lefuttatni (ha még nincs fent a pip3 csomagkezelő a gépünkön).

Telepítése:

```
sudo apt install python3-pip

pip3 install requests --user -U
```

requests telepítése / frissítése

A **requests** modul használata

```
import requests

url = "http://index.hu"
r = requests.get(url)
print(r.text)
```

Feladat

Dívány szavazatok testreszabása

Link: https://arato.inf.unideb.hu/szathmary.laszlo/pmwiki/index.php?n=Py3.20121026a

JSON szerializáció

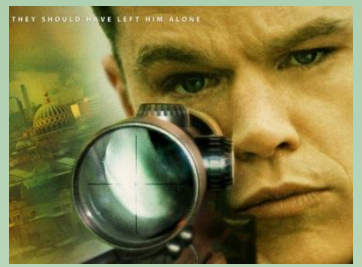

- http://json.org/
- http://en.wikipedia.org/wiki/Json

A **json** modul segítségével memóriában lévő Python objektumokat tudunk JSON formátumba szerializálni.

Szerializáció

Egy adatszerkezet vagy objektum konvertálása olyan formátumba, amelyet le lehet tárolni pl. egy fájlban (vagy hálózaton keresztül át lehet küldeni), majd később ugyanabban, vagy egy másik számítási környezetben „újra lehet éleszteni”.

adatszerkezet, objektum $\xrightarrow{\text{szerializáció}}$ file, bitsorozat

file, bitsorozat $\xrightarrow{\text{de-szerializáció}}$ adatszerkezet, objektum

Formátumok: XML, JSON, YAML, stb.

A JSON sok esetben használható az XML alternatívájaként

- szintén szöveg-alapú, az ember számára is jól olvasható
- szintén hierarchikus felépítésű
- szintén nagyszerűen használható alkalmazások közti kommunikációra
- egyszerűbb mint az XML
- nem annyira bőbeszédű, rövidebb
- gyorsabban lehet írni/olvasni

XML:

```
<Person>
   <FirstName>Homer</FirstName>
   <LastName>Simpson</LastName>
   <Relatives>
      <Relative>Grandpa</Relative>
      <Relative>Marge</Relative>
      <Relative>The Boy</Relative>
      <Relative>Lisa</Relative>
   </Relatives>
</Person>
```

JSON:

```
{
   "firstName": "Homer",
   "lastName": "Simpson",
   "relatives": [ "Grandpa", "Marge", "The Boy", "Lisa" ]
}
```

XML:

```
<persons>
 <person>
  <name>Ford Prefect</name>
  <gender>male</gender>
 </person>
 <person>
  <name>Arthur Dent</name>
  <gender>male</gender>
 </person>
 <person>
  <name>Tricia McMillan</name>
  <gender>female</gender>
 </person>
</persons>
```

JSON:

```
[
  {
    "name": "Ford Prefect",
    "gender": "male"
  },
  {
    "name": "Arthur Dent",
    "gender": "male"
  },
  {
    "name": "Tricia McMillan",
    "gender": "female"
  }
]
```

XML:

```
<settings>
    <path>/home/luke/Dropbox/Public</path>
    <user_id>123456</user_id>
    <auto_sync>True</auto_sync>
</settings>
```

(forrás: Dropbox Publicus)

JSON:

```
{
   "path": "/home/luke/Dropbox/Public",
   "user_id": 123456,
   "auto_sync": true
}
```

JSON szintaktikai szabályok

- az adatok kulcs/érték párok
- az adatok vesszővel vannak elválasztva
- a kapcsos zárójelek objektumot jelölnek
- a szögletes zárójelek tömböt jelölnek

JSON értékek

Egy JSON érték a következő lehet:

- szám (egész vagy lebegőpontos)
- sztring (idézőjelek között)
- boolean (true vagy false)
- tömb (szögletes zárójelek között)
- objektum (kapcsos zárójelek között)
- null

JSON **file** betöltése

input file (person.json)

```
1  {
2      "last": "Doe",
3      "first": "John",
4      "age": 39,
5      "sex": "M",
6      "registered": true,
7      "salary": 70000
8  }
```

pretty print
(adatszerkezetek olvashatóbb kiíratása)

json modul
(json fájlok írása / olvasása)

```
3   from pprint import pprint
4   import json
5
6
7   def read_file():
8       f = open('person.json', 'r')
9       d = json.load(f)
10      f.close()
11
12      print(type(d))
13      pprint(d, indent=4)
```

```
{    'age': 39,
     'first':  'John',
     'last':  'Doe',
     'registered': True,
     'salary': 70000,
     'sex':  'M'}
```

kimenet (szótár)

visszaadott érték: Python adatszerkezet
(itt a példában: dictionary)

JSON **sztring** betöltése

```
7   def read_string():
8       s = """{
9       "path": "/home/luke/Dropbox/Public",
10      "user_id": 123456,
11      "auto_sync": true
12  }"""
13
14      d = json.loads(s)
15
16      print(d)
```

(lásd settings.py)

loads
(**s** mint sztring)

Lényeg

A *json* modul vesz egy sztringet (akár egy fájlból, akár egy karaktersorozatból), s abból **felépít egy Python objektumot** (pl. listát, szótárat). Vagyis a sztringet nem nekem kell parse-olni, hanem a modul ezt elvégzi helyettünk!

Feladatok

Saját IP címem lekérdezése

Link: https://arato.inf.unideb.hu/szathmary.laszlo/pmwiki/index.php?n=Py3.20120920g

Reddit-ről tájképek letöltése

Link: https://arato.inf.unideb.hu/szathmary.laszlo/pmwiki/index.php?n=Py3.20121126a

Adatszerkezet kiírása **file-ba** JSON formátumban

(lásd write_person.py)

```
3   import json
4
5   def write_file():
6       person = {
7           'last': 'Doe',
8           'first': 'John',
9           'age': 39,
10          'sex': 'M',
11          'registered': True,
12          'salary': 70000,
13      }
14
15      f = open('employee.json', 'w')
16      json.dump(person, f)
17      f.close()
```

Python szótár

json.dump(data_structure, file_handler)

```
print(json.dumps(person))
```

az adatszerkezetből JSON sztringet készít, s azt adja vissza

```
json.dump(person, f, indent=4)
```

csinos kiíratás

```
json.dump(person, f,
    indent=4, sort_keys=True)
```

csinos kiíratás, kulcsok szerint rendezve

Feladatok

házi feladat

1. [20120816b] get_alap.py
2. [20120815k] szökés Alcatrazból